



# Universidad Europea

**UNIVERSIDAD EUROPEA DE MADRID**

**Proyecto de Big Data 1**

**Trabajo Grupal:  
Modelo Dimensional del Data Warehouse y Modelo Relacional del  
Proyecto GTP**



**Integrantes: Pablo Sánchez, Juan Manuel Palencia, Pablo  
Mata Rius, Maria Paula Aguirre  
Profesor: Álvaro Sánchez Perez  
07/10/2025**

**Grado en Ingeniería Matemática Aplicada al Análisis de Datos  
Escuela de Arquitectura, Ingeniería y Diseño**

## Indice

|                                               |    |
|-----------------------------------------------|----|
| Modelo Dimensional del Datawarehouse .....    | 4  |
| Introduccion .....                            | 4  |
| Objetivo del Data Warehouse.....              | 4  |
| Modelo Dimensional: Esquema en Estrella ..... | 4  |
| Estructura general del Data Warehouse .....   | 5  |
| Tabla de hechos .....                         | 5  |
| Campos principales: .....                     | 5  |
| Tabla de dimensiones .....                    | 6  |
| dim_country .....                             | 6  |
| dim_geo.....                                  | 7  |
| dim_time .....                                | 7  |
| dim_unit .....                                | 8  |
| dim_measure .....                             | 8  |
| dim_dataset .....                             | 9  |
| dim_demography .....                          | 9  |
| dim_code.....                                 | 10 |
| Relaciones entre tablas.....                  | 10 |
| Ventajas del modelo dimensional.....          | 10 |
| Conclusion del dimensional .....              | 11 |
| Modelo Entidad Relacion.....                  | 11 |
| Introduccion .....                            | 11 |
| Objetivos del modelo .....                    | 11 |
| Alcance.....                                  | 11 |
| Vision General del modelo.....                | 12 |
| Descripcion de entidades .....                | 12 |
| Country.....                                  | 12 |
| Geo_area .....                                | 13 |
| Source.....                                   | 13 |
| Dataset.....                                  | 13 |
| Unit.....                                     | 13 |
| Variable .....                                | 14 |
| Classification_system.....                    | 14 |

|                                             |    |
|---------------------------------------------|----|
| classification_code .....                   | 14 |
| variable_classification.....                | 14 |
| Demographic_profile .....                   | 14 |
| Period .....                                | 15 |
| Observation .....                           | 15 |
| Relaciones y cardinalidades .....           | 15 |
| Normalizacion .....                         | 16 |
| Reglas de integridad.....                   | 16 |
| Beneficios del modelo Entidad-Relacion..... | 16 |
| Conclusion del modelo Entidad-Relacion..... | 16 |

## **Modelo Dimensional del Datawarehouse**

### **Introduccion**

El presente documento describe la estructura del Data Warehouse (DW) diseñado para el proyecto GTP (Green Turning Point). El objetivo principal del modelo es integrar, limpiar y organizar de forma coherente los datos obtenidos de fuentes internacionales como OECD, Eurostat, EEA y Copernicus que contienen indicadores económicos, ambientales, sociales y de innovación.

El modelo se implementa bajo un esquema en estrella, compuesto por una tabla de hechos que almacena los valores numéricos de las observaciones y un conjunto de tablas de dimensiones que proporcionan el contexto descriptivo. Este diseño permite realizar análisis comparativos, temporales y geográficos de manera eficiente, facilitando el proceso de toma de decisiones y el desarrollo de dashboards analíticos.

### **Objetivo del Data Warehouse**


El modelo tiene como finalidad:

- Consolidar y estandarizar información procedente de múltiples fuentes heterogéneas.
- Garantizar la consistencia temporal, geográfica y semántica de los datos.
- Permitir el análisis conjunto de indicadores económicos, ambientales y sociales.
- Facilitar el estudio de relaciones complejas como la Curva Ambiental de Kuznets (EKC).
- Servir como base para modelos predictivos, visualizaciones interactivas y procesos de data mining.

### **Modelo Dimensional: Esquema en Estrella**

El modelo dimensional del proyecto GTP sigue un esquema estrella, en el cual una tabla de hecho central (fact\_observation) se relaciona con varias tablas de dimensiones (dim\_\*\*\*). Cada dimensión describe un aspecto del hecho observado (país, tiempo, unidad, medida, fuente, etc.), permitiendo el análisis desde distintos enfoques.

## Estructura general del Data Warehouse



### Tabla de hechos

“Fact\_observation”, es el núcleo del Data Warehouse. Cada registro representa así una observación cuantitativa de una medida específica (por ejemplo, emisiones de CO<sub>2</sub>, PIB per cápita, o tasa de empleo) en una localización y periodo determinados.

Campos principales:

| Campo | Descripción |
|-------|-------------|
|-------|-------------|

|                     |                                                        |
|---------------------|--------------------------------------------------------|
| obs_id              | Identificador único de la observación.                 |
| dataset_id          | Fuente o conjunto de datos de procedencia.             |
| measure_id          | Indicador o variable medida.                           |
| unit_id             | Unidad de medida asociada.                             |
| time_id             | Periodo temporal de observación.                       |
| geo_id / country_id | Referencias geográficas.                               |
| value_numeric       | Valor numérico de la observación.                      |
| extraction_dt       | Fecha de extracción o carga del dato.                  |
| source_table        | Archivo o tabla de origen.                             |
| demog_id / code_id  | Desgloses opcionales (demográficos o clasificaciones). |

La tabla de hechos almacena los valores estandarizados listos para análisis, evitando duplicaciones y garantizando la trazabilidad a la fuente original.

## Tabla de dimensiones

### **dim\_country**

Contiene los países normalizados conforme al estándar ISO-3166 (códigos ISO2 e ISO3). Sirve como punto de referencia para las dimensiones geográficas y las observaciones por país.

| Campo        | Descripcion                                    |
|--------------|------------------------------------------------|
| country_id   | Identificador único.                           |
| iso3         | Código ISO de tres letras (ej. ESP, FRA, DEU). |
| iso2         | Código ISO de dos letras.                      |
| country_name | Nombre oficial del país.                       |

### **dim\_geo**

Define las unidades espaciales de análisis: países, regiones, ciudades o áreas funcionales urbanas (FUA). Cada registro se vincula con su país correspondiente.

| Campo      | Descripcion                                          |
|------------|------------------------------------------------------|
| Geo_id     | Clave Primaria.                                      |
| Geo_level  | Nivel Geografico (Country, región, FUA, city, NUTS). |
| Geo_code   | Codigo oficial del área.                             |
| Geo_name   | Nombre de la región o ciudad.                        |
| Country_id | Relación con dim_country.                            |

### **dim\_time**

Normaliza la dimensión temporal. Permite trabajar con datos anuales, trimestrales, mensuales o diarios, garantizando uniformidad temporal y compatibilidad con análisis de series.

| Campo                     | Descripcion                                                      |
|---------------------------|------------------------------------------------------------------|
| time_id                   | Clave Primaria.                                                  |
| freq                      | Frecuencia (A = anual, Q = trimestral, M = mensual, D = diaria). |
| year, quarter, month, day | Componentes temporales.                                          |
| date_utc                  | Fecha base en formato UTC.                                       |

### **dim\_unit**

Gestiona las unidades de medida y sus factores de conversión. Permite reescalar métricas para mantener coherencia entre datasets (por ejemplo, pasar de m<sup>2</sup> a km<sup>2</sup> o de % a ratio).

| Campo              | Descripción                                     |
|--------------------|-------------------------------------------------|
| unit_id            | Clave Primaria.                                 |
| unit_code          | Código de la unidad (km2, EUR, t, ratio, etc.). |
| unit_name          | Descripción textual.                            |
| base_unit_code     | Unidad base para la conversión.                 |
| multiplier_to_base | Factor de conversión.                           |

### **dim\_measure**

Describe los indicadores analizados en el DW. Ejemplos: emisiones de gases de efecto invernadero (ghg\_total), PIB per cápita (gdp\_pc\_pps), satisfacción vital (life\_satisfaction), densidad de cobertura arbórea (tcd\_pct).

| Campo        | Descripción                   |
|--------------|-------------------------------|
| measure_id   | Identificador del indicador.  |
| measure_code | Código en formato snake_case. |
| measure_name | Nombre legible del indicador. |
| description  | Definición o fuente.          |

### **dim\_dataset**

Registra las fuentes o conjuntos de datos integrados en el DW. Cada archivo o serie original se identifica mediante un código único.

| Campo        | Descripción                                        |
|--------------|----------------------------------------------------|
| dataset_id   | Identificador único.                               |
| dataset_code | Código del dataset (ej. OECD_GDP, EUROSTAT_BLI_1). |
| source_name  | Nombre de la institución fuente.                   |
| source_url   | URL o ubicación del recurso original.              |
| license      | Tipo de licencia o derechos de uso.                |
| notes        | Observaciones adicionales.                         |

### **dim\_demography**

Tabla opcional que recoge desgloses demográficos: sexo, grupo de edad, nivel educativo o condición laboral. Su campo concat\_key garantiza la unicidad de combinaciones.

| Campo           | Descripción                         |
|-----------------|-------------------------------------|
| demog_id        | Identificador.                      |
| Sex             | Género (male, female, other).       |
| age_group       | Grupo etario (15–24, 25–34, etc.).  |
| work_status     | Situación laboral.                  |
| education_iscED | Nivel educativo según ISCED-11.     |
| other_attrs     | Campos adicionales en formato JSON. |

### **dim\_code**

Contiene clasificaciones estandarizadas utilizadas en los datasets (NACE, SIEC, SEEA, CEPA, etc.), útiles para desgloses por actividad económica, sector o tipo de recurso.

| Campo       | Descripción                          |
|-------------|--------------------------------------|
| code_id     | Identificador.                       |
| code_system | Nombre del sistema de clasificación. |
| code_value  | Código o categoría.                  |
| code_label  | Descripción o etiqueta.              |

### **Relaciones entre tablas**

Las relaciones en el esquema estrella se establecen de la siguiente forma:

- fact\_observation.dataset\_id → dim\_dataset.dataset\_id
- fact\_observation.measure\_id → dim\_measure.measure\_id
- fact\_observation.unit\_id → dim\_unit.unit\_id
- fact\_observation.time\_id → dim\_time.time\_id
- fact\_observation.geo\_id → dim\_geo.geo\_id
- fact\_observation.country\_id → dim\_country.country\_id
- fact\_observation.demog\_id → dim\_demography.demog\_id
- fact\_observation.code\_id → dim\_code.code\_id

### **Ventajas del modelo dimensional**

1. Escalabilidad: permite incorporar nuevas fuentes y medidas sin rediseñar la estructura.
2. Homogeneidad: todos los datos se integran bajo un mismo esquema estándar.
3. Trazabilidad: cada observación conserva referencia a su origen y fecha de extracción.
4. Compatibilidad: apto para integrarse con sistemas de BI y análisis avanzado (Power BI, Tableau, Oracle Analytics Cloud).
5. Eficiencia analítica: consultas rápidas y agregaciones sencillas por país, año, indicador o fuente.

6. Separación semántica: los datos cuantitativos se almacenan en la tabla de hechos, mientras que las descripciones y categorías se encuentran en las dimensiones

## Conclusion del dimensional

El Data Warehouse GTP constituye un sistema centralizado y normalizado que unifica información económica, ambiental y social en un modelo común. Gracias a su diseño basado en un esquema en estrella, garantiza un acceso eficiente, escalable y consistente a los datos, facilitando la explotación analítica y la toma de decisiones estratégicas. Su estructura modular permite incorporar nuevas fuentes, indicadores y desgloses sin modificar la arquitectura principal, consolidando así una infraestructura robusta para el análisis integral de la sostenibilidad y el desarrollo verde.

## Modelo Entidad Relacion

### Introduccion

El presente documento describe el modelo Entidad–Relación (E/R) del proyecto GTP (Green Turning Point), cuyo propósito es almacenar y gestionar de forma estructurada la información proveniente de múltiples fuentes internacionales, principalmente OECD, Eurostat, EEA y Copernicus. Este modelo E/R constituye la base de datos operacional del proyecto, orientada al registro, control y trazabilidad de las observaciones numéricas, sus metadatos y las entidades asociadas (países, periodos, unidades, variables, etc.). Su diseño busca garantizar la integridad referencial, la normalización de la información y la consistencia semántica entre distintas fuentes

### Objetivos del modelo

- Representar de forma coherente las entidades y relaciones que intervienen en los datos del proyecto GTP.
- Garantizar la **unicidad y trazabilidad** de cada observación registrada.
- Facilitar la **integración de múltiples fuentes** mediante catálogos estandarizados (país, unidad, clasificación, periodo, etc.).
- Permitir el **almacenamiento normalizado** de datos de carácter económico, ambiental, social y de innovación.
- Mantener la **consistencia temporal, geográfica y conceptual** entre todas las entidades.

### Alcance


El modelo abarca las entidades necesarias para describir completamente cada registro de información, considerando:

- Países y áreas geográficas (según estándares ISO, NUTS y FUA).
- Fuentes oficiales e instituciones de origen.
- Datasets y variables o indicadores cuantitativos.
- Unidades de medida y factores de conversión.
- Periodos de observación (anuales, trimestrales, mensuales o diarios).

- Perfiles demográficos y códigos de clasificación.
- Observaciones numéricas con metadatos de extracción y procedencia.

## Vision General del modelo

El modelo E/R se compone de entidades principales, catálogos auxiliares y una tabla central de observaciones. Cada observación almacena un valor cuantitativo y referencias a los catálogos que describen su contexto.



## Descripcion de entidades

## Country

## Catalogo de países normalizados según el estándar ISO-3166

- **Atributos:**
  - country\_id (PK)
  - iso3 (UK)
  - iso2 (UK)
  - country\_name
- **Función:** garantizar la consistencia geográfica y permitir la vinculación con áreas subnacionales.

## Geo\_area

Define unidades espaciales de análisis (países, regiones, NUTS, FUA o ciudades).

- **Atributos:**
  - geo\_id (PK)
  - geo\_level (ENUM: country, region, NUTS, FUA, city)
  - geo\_code (UK por nivel)
  - geo\_name
  - country\_id (FK → country)
- **Función:** almacenar las subdivisiones territoriales asociadas a cada país.

## Source

Registra las instituciones u organismos que proveen los datos.

- **Atributos:**
  - source\_id (PK)
  - source\_name (UK)
  - source\_url
  - license
  - notes
- **Ejemplos:** OECD, Eurostat, European Environment Agency (EEA), Copernicus.

## Dataset

Representa un conjunto de datos concreto publicado por una fuente.

- **Atributos:**
  - dataset\_id (PK)
  - dataset\_code (UK)
  - title
  - theme (ENUM: economic, environmental, social, innovation, energy, finance)
  - source\_id (FK → source)
- **Ejemplo:** OECD\_GDP, EUROSTAT\_BLI\_INDICATORS\_1, EEA\_AIR\_POLLUTANTS.

## Unit

Contiene las unidades de medida utilizadas y sus equivalencias.

- **Atributos:**
  - unit\_id (PK)
  - unit\_code (UK; p. ej., km2, ug/m3, t, EUR, ratio)
  - unit\_name
  - base\_unit\_code
  - multiplier\_to\_base
- **Función:** mantener la coherencia entre diferentes escalas de medida.

## Variable

Define las variables o indicadores medidos dentro de cada dataset.

- **Atributos:**
  - variable\_id (PK)
  - variable\_code (UK)
  - variable\_name
  - description
  - default\_unit\_id (FK → unit)
  - dataset\_id (FK → dataset)
- **Ejemplos:** emisiones de gases de efecto invernadero (ghg\_total), PIB per cápita (gdp\_pc\_pps), energía renovable (renewable\_energy\_pct).

## Classification\_system

Define los sistemas de clasificación utilizados (NACE, SIEC, CEPA, SEEA, etc.).

- **Atributos:**
  - classification\_system\_id (PK)
  - system\_code (UK; p. ej., NACE)
  - system\_name

## classification\_code

Registra los códigos específicos dentro de cada sistema de clasificación.

- **Atributos:**
  - classification\_code\_id (PK)
  - classification\_system\_id (FK → classification\_system)
  - code\_value (UK por sistema)
  - code\_label

## variable\_classification

Tabla puente (M:N) entre variables y códigos de clasificación.

- **Atributos:**
  - variable\_id (FK → variable)
  - classification\_code\_id (FK → classification\_code)
  - **PK compuesta:** (variable\_id, classification\_code\_id)

## Demographic\_profile

Define los desgloses demográficos utilizados en algunas variables.

- **Atributos:**
  - demog\_id (PK)
  - sex (ENUM: male, female, other)
  - age\_group
  - work\_status
  - education\_iscED (según ISCED-11)
  - other\_attrs (JSON)
  - concat\_key (columna generada para unicidad)
- **Ejemplo:** Mujeres de 25–34 años empleadas con nivel ISCED 5–8.

## Period

Define los periodos temporales de observación.

- **Atributos:**
  - period\_id (PK)
  - freq (A, Q, M, D)
  - year, quarter, month, day
  - timestamp\_utc (fecha normalizada)
- **Función:** evitar duplicación de fechas y soportar diferentes frecuencias temporales.

## Observation

Es la tabla central del modelo. Cada registro representa una observación única con su valor y contexto.

- **Atributos:**
  - observation\_id (PK)
  - dataset\_id (FK → dataset)
  - variable\_id (FK → variable)
  - unit\_id (FK → unit)
  - geo\_id (FK → geo\_area)
  - country\_id (FK → country)
  - period\_id (FK → period)
  - value\_numeric
  - value\_status (estado del dato: estimado, provisional, final, etc.)
  - source\_table
  - source\_file
  - extraction\_dt
  - demog\_id (FK → demographic\_profile, opcional)
  - classification\_code\_id (FK → classification\_code, opcional)

## Relaciones y cardinalidades

- country 1—N geo\_area → un país puede tener múltiples áreas o regiones.
- source 1—N dataset → una fuente puede publicar varios datasets.
- dataset 1—N variable → cada dataset puede incluir múltiples variables.
- unit 1—N variable → cada variable tiene una unidad por defecto.
- variable M—N classification\_code (vía variable\_classification).
- classification\_system 1—N classification\_code → un sistema agrupa varios códigos.
- period 1—N observation → múltiples observaciones pueden compartir el mismo periodo.
- geo\_area 1—N observation → cada observación se asocia a un área geográfica.

- country 1—N observation → cada observación pertenece a un país.
- demographic\_profile 1—N observation → solo en datos con desglose demográfico.

## **Normalizacion**

El modelo cumple la Tercera Forma Normal (3NF):

- Cada entidad almacena únicamente atributos de su dominio.
- Las dependencias funcionales están correctamente representadas.
- Se evitan duplicaciones mediante claves primarias y foráneas.
- Los catálogos (country, unit, classification\_system, etc.) garantizan consistencia semántica.

## **Reglas de integridad**

- Claves naturales conservadas: códigos ISO, geo\_code, system\_code + code\_value.
- Referencias cruzadas aseguradas mediante claves foráneas (InnoDB).
- Unicidad geográfica y temporal garantizada en geo\_area y period.
- Registros únicos en observation según la combinación de claves contextuales.

## **Beneficios del modelo Entidad-Relacion**

- Coherencia estructural: cada valor está asociado a su contexto exacto (país, periodo, unidad, variable).
- Escalabilidad: se pueden incorporar nuevas fuentes, variables y clasificaciones sin alterar la estructura.
- Trazabilidad: cada observación mantiene el vínculo con su fuente y archivo de origen.
- Estandarización: unifica los formatos geográficos, temporales y de unidades.
- Mantenibilidad: la separación por entidades facilita validaciones, auditorías y actualizaciones.

## **Conclusion del modelo Entidad-Relacion**

El modelo Entidad-Relación del proyecto GTP proporciona una arquitectura normalizada, coherente y escalable para la gestión de datos multitemáticos e internacionales. Permite el almacenamiento eficiente de observaciones y metadatos, garantizando la calidad, integridad y consistencia de la información en todas las etapas del proceso. Su diseño modular y normalizado asegura que la base de datos sea flexible frente a la incorporación de nuevas variables, periodos o fuentes, manteniendo la trazabilidad y la fiabilidad de los datos en todo momento.