

1. EUROSTAT.....	3
1. El Atributo Maestro: Qué descargar.....	3
1. El Atributo Maestro: Qué descargar.....	4
2. El Atributo de Precisión: Filtros (Vital).....	4
3. Los Atributos Técnicos.....	5
🚀 Recetario de Comandos (Copia y Pega para probar).....	6
A. Para Datos Nacionales Básicos.....	6
B. Para Datos Regionales (Madrid).....	6
C. Para Tablas "Pesadas" (Industria).....	6
D. Para Datos de Población/Salud.....	6
2. HRL.....	6
📘 Manual de Atributos: HRL_extract.py.....	6
1. --service (El Menú Principal).....	6
2. --layer (El Plato Específico).....	7
3. --bbox (El Mapa - ¡OJO!).....	7
4. --size (La Resolución).....	8
🚀 Recetario de Comandos (Copia y Pega).....	8
A. Mapa de Árboles (Tu KPI Verde).....	8
B. Mapa de Asfalto (Tu KPI Gris).....	8
C. Mapa de Cambios (Evolución).....	8
3. INVESTEU.....	9
📘 Manual de Atributos: InvestEU_extract.py.....	9
1. --what (El Modo de Operación).....	9
2. --out-dir (La Salida).....	9
3. --years (Etiqueta Informativa).....	10
🔒 Variables de Entorno (.env) - ¡CRÍTICAS!.....	10
📘 Manual de Atributos: InvestEU_extract.py.....	11
1. --what (El Modo de Operación).....	11
2. --out-dir (La Salida).....	11
3. --years (Etiqueta Informativa).....	11
🔒 Variables de Entorno (.env) - ¡CRÍTICAS!.....	11
🚀 Recetario de Comandos.....	12
A. El Comando Estándar (Todo).....	12
B. Solo Web Scraping (Rápido).....	12
C. Forzar un PDF Nuevo (Avanzado).....	12
4. OECD.....	13
📘 Manual de Atributos: OECD_extract.py.....	13
1. --only (El Menú a la Carta).....	13
2. --start y --end (La Ventana Temporal).....	13
3. Control de Bloqueos (Rate Limiting) - ¡VITAL!.....	14
4. --overwrite (El Borrador).....	14
🚀 Recetario de Comandos.....	14

A. El Pack "Curva de Kuznets" (Lo esencial).....	14
B. Datos de Bienestar y Sociedad.....	14
C. Modo "Reparación" (Forzar descarga).....	14
6. SENTINEL-2.....	15
 Manual de Atributos: Sentinel-2_extract.py.....	15
1.  Argumentos Geográficos (El "Dónde").....	15
2.  Argumentos Temporales (El "Cuándo").....	16
3.  Argumentos de Datos (El "Qué").....	16
 Recetario de Comandos (Para tu TFM).....	18
A. El Dato Científico (Cálculo NDVI).....	18
B. La Máscara de Limpieza (Quitar Nubes).....	18
C. La Evidencia Visual (Informe).....	18

1. EUROSTAT

1. El Atributo Maestro: Qué descargar

Atributo	Ejemplo	¿Para qué sirve?
<code>--datasets</code>	<code>--datasets gdp_per_capita</code>	Obligatorio. Define qué indicadores quieres. • Puedes poner uno solo. • Puedes poner varios separados por comas: <code>gdp_per_capita,ghg_emissions</code>. • Puedes poner <code>all</code> para intentar descargar todo lo que hay en el script (¡cuidado con los filtros!).

Basándome en el código de [eurostat_extract.py](#) que tienes, aquí tienes la **guía definitiva y detallada** de todos los atributos que puedes usar para controlar la descarga de datos de Eurostat.

Este script es un **cliente de API SDMX**. Su trabajo es negociar con la base de datos de Eurostat para traer solo los trozos de información que necesitas.

1. El Atributo Maestro: Qué descargar

Atributo	Ejemplo	¿Para qué sirve?
<code>--dataset s</code>	<code>--datasets gdp_per_capita</code>	Obligatorio. Define qué indicadores quieres. • Puedes poner uno solo. • Puedes poner varios separados por comas: <code>gdp_per_capita,ghg_emissions</code>. • Puedes poner all para intentar descargar todo lo que hay en el script (¡cuidado con los filtros!).

Lista de Datasets disponibles (según tu código):

- **Económicos:** `gdp_per_capita`, `employment_by_sector`, `gross_fixed_capital`, `productivity`.
- **Sociales:** `poverty_rate`, `life_satisfaction`, `median_income`, `self_perceived_health`.
- **Ambientales:** `ghg_emissions`, `environmental_expenditure`, `renewable_energy`.
- **Regionales (NUTS 2):** `regional_gdp_n2`, `regional_unemployment_n2`, `regional_education_n2`.
- **Grupos (Varios archivos):** `egss` (Economía ambiental), `circular` (Economía circular).

2. El Atributo de Precisión: Filtros (Vital)

Este es el atributo más importante para evitar errores. Eurostat tiene tablas gigantes; los filtros le dicen a la API "dame solo esto".

Atributo	Ejemplo	¿Para qué sirve?
<code>--filters</code>	<code>--filters "geo=ES"</code>	Envía parámetros de corte a la API. El formato es clave=valor unidos por <code>&</code> .

Los filtros clave que debes dominar:

1. **geo (Geografía):**
 - **geo=ES: España (País).** Úsalo para datos nacionales (PIB, Emisiones, Impuestos).
 - **geo=ES30: Comunidad de Madrid (NUTS 2).** Úsalo para datos regionales (Educación, Paro regional).
 - **geo=ES300: Madrid Ciudad (NUTS 3).** (Pocos datasets soportan esto, cuidado con el Error 400).
2. **time (Tiempo):**
 - **time=2000:2024:** Rango desde el año 2000 hasta 2024.
 - **time=2023:** Solo el año 2023.
3. **nace_r2 (Sector Industrial):**
 - **nace_r2=TOTAL: ¡Fundamental!** Sirve para datasets como **gross_fixed_capital** o **employment_by_sector**. Si no lo pones, intentará bajar el desglose de cientos de industrias y fallará (Error 413).
4. **sex (Género):**
 - **sex=T:** Total (Hombres + Mujeres). Necesario en tablas demográficas o de salud (**self_perceived_health**) para no duplicar filas.
5. **unit (Unidad de medida):**
 - A veces útil si la tabla devuelve muchas unidades (Euros, Porcentaje, Millones...). Ej: **unit=PC_GDP** (% del PIB).

3. Los Atributos Técnicos

Atributo	Ejemplo	¿Para qué sirve?
<code>--eager-merge</code>	(Sin valor)	Interruptor. Si descargas un "Grupo" (como <code>egss</code> que tiene parte 1 y parte 2), este comando le dice al script que fusion e los CSVs resultantes en uno solo (<code>egss.csv</code>). Recomendado usarlo siempre.
<code>--out-dir</code>	<code>--out-dir data/test</code>	Cambia la carpeta donde se guardan los CSV. Por defecto es <code>data/eurostat</code> .



Recetario de Comandos (Copia y Pega para probar)

Aquí tienes las combinaciones exactas que funcionan para los distintos tipos de datos de tu TFM.

A. Para Datos Nacionales Básicos

(PIB, Emisiones, Gasto Ambiental - Solo existen a nivel país)

```
python ETL/script/eurostat_extract.py --datasets gdp_per_capita,ghg_emissions  
--eager-merge --filters "geo=ES&time=2000:2024"
```

B. Para Datos Regionales (Madrid)

(Educación, Paro - Bajan a nivel Comunidad Autónoma NUTS 2)

```
python ETL/script/eurostat_extract.py --datasets regional_education_n2 --eager-merge  
--filters "geo=ES30&time=2000:2024"
```

C. Para Tablas "Pesadas" (Industria)

(Inversión de Capital - Requiere filtro de sector para no explotar)

```
python ETL/script/eurostat_extract.py --datasets gross_fixed_capital --eager-merge --filters  
"geo=ES&time=2000:2024&nace_r2=TOTAL"
```

D. Para Datos de Población/Salud

(Requiere filtro de sexo)

```
python ETL/script/eurostat_extract.py --datasets self_perceived_health --eager-merge  
--filters "geo=ES&time=2000:2024&sex=T"
```

2. HRL



Manual de Atributos: **HRL_extract.py**

1. **--service** (El Menú Principal)

Define qué tipo de producto temático quieres descargar.

- **Opciones (según tu código):**
 - **tree_cover**: **Densidad Arbórea**. Fundamental para tu "Eje Y" (Inversión Ambiental). Muestra bosques y árboles urbanos.
 - **impervious**: **Impermeabilidad (Asfalto/Cemento)**. Fundamental para tu "Eje X" (Desarrollo Urbano). Muestra carreteras, edificios y parkings.

- **urban_atlas**: Uso del suelo urbano detallado (zonas industriales vs residenciales).
- **small_woody**: Pequeños elementos leñosos (setos, arbustos en lindes agrícolas).

2. --layer (El Plato Específico)


Dentro del servicio elegido, ¿qué capa de datos quieres?

- **Para tree_cover:**
 - **density**: (Recomendado) Un mapa de 0 a 100% de densidad de hojas.
 - **leaf_type**: Tipo de hoja (caduca/perenne).
- **Para impervious:**
 - **density**: (Recomendado) Un mapa de 0 a 100% de "sellado" del suelo.
 - **builtup**: Mapa binario (Sí/No hay edificio).
 - **change**: Mapa de cambios (dónde se ha construido nuevo entre 2015 y 2018).

3. --bbox (El Mapa - ¡OJO!)

Define el rectángulo geográfico que quieres descargar.

- **Formato**: **minX,minY,maxX,maxY** (4 números separados por comas).
- **Sistema de Coordenadas: EPSG:3857 (Web Mercator)**.
 - **⚠ NO** uses Latitud/Longitud (grados). Tienes que usar Metros.
 - *Ejemplo Madrid*: **-434145,4891968,-367311,4951156**
- **Truco Técnico**: Como las coordenadas suelen ser negativas (ej: **-434...**), debes unir la bandera y el valor con un igual (=) en tu **run_all.py** para que no falle:
"--bbox=-434145,4891968,-367311,4951156"



Shutterstock

4. **--size** (La Resolución)

Define el tamaño de la imagen resultante en píxeles (ancho y alto).

- **Por defecto:** 1024 (1024x1024 píxeles).
 - **Recomendación:** Para una ciudad como Madrid, 1024 se queda corto (se ve borroso). Súbelo a 2048 o 4096 para tener más detalle y que cada píxel represente menos metros reales.
-



Recetario de Comandos (Copia y Pega)

Estos son los comandos exactos para ejecutar manualmente en terminal (recuerda que en `run_all.py` ya los tienes configurados).

A. Mapa de Árboles (Tu KPI Verde)

Para saber cuánto verde real hay en la ciudad.

```
python ETL/script/HRL_extract.py \  
--service tree_cover \  
--layer density \  
--bbox -434145,4891968,-367311,4951156 \  
--size 2048
```

B. Mapa de Asfalto (Tu KPI Gris)

Para medir la expansión urbana y el desarrollo.

```
python ETL/script/HRL_extract.py \  
--service impervious \  
--layer density \  
--bbox -434145,4891968,-367311,4951156 \  
--size 2048
```

C. Mapa de Cambios (Evolución)

Para ver solo dónde se ha construido nuevo (útil para ver crecimiento rápido).

```
python ETL/script/HRL_extract.py \  
--service impervious \  
--layer change \  
--bbox -434145,4891968,-367311,4951156 \  
--size 2048
```


3. INVESTEU

Manual de Atributos: **InvestEU_extract.py**

1. **--what** (El Modo de Operación)

Define qué parte del portal de InvestEU quieres atacar.

Opción	Descripción	¿Cuándo usarlo?
<code>all</code>	(Por defecto) Ejecuta ambas tareas: descarga la lista web Y procesa los PDFs.	Para la ejecución normal del ETL.
<code>list</code>	Solo hace Web Scraping del listado de operaciones ("Operations List"). Genera <code>operations_list.csv</code> .	Si solo te interesa saber qué proyectos existen, pero no quién recibió el dinero final.
<code>recipients</code>	Solo hace PDF Scraping de los documentos de beneficiarios. Genera <code>final_recipients.csv</code> .	Si la web falla pero quieres extraer datos de los PDFs.

2. **--out-dir** (La Salida)

Define dónde se guardarán los CSV resultantes.

- **Por defecto:** `data/raw/investeu`
- **Archivos generados:**
 - `operations_list.csv` (Datos de la web)
 - `final_recipients_202X.csv` (Datos de las tablas del PDF)

3. `--years` (Etiqueta Informativa)

- **Uso:** `--years 2024`
- **Función:** Es un argumento opcional que ayuda a nombrar el archivo de salida si estás forzando la descarga de un PDF específico manualmente. En la ejecución automática (`all`), el script intenta adivinar el año por sí mismo.

Variables de Entorno (`.env`) - ¡CRÍTICAS!

A diferencia de los otros scripts, este **depende totalmente** de tu archivo `.env` para configuraciones avanzadas que no se pasan por terminal.

Variable	Descripción
<code>INVESTEU_RECIPIENT_PDFS</code>	(Opcional) Lista de URLs de PDFs separadas por comas. Si no la pones, el script usa una URL interna por defecto (la lista oficial del EIB). Úsalo si el EIB publica un PDF nuevo y quieres forzar su descarga.
<code>INVESTEU_BASE_SLEEP</code>	Segundos de espera entre páginas web o descargas de PDF. Recomendado: <code>300</code> (5 min) para evitar bloqueos.
<code>INVESTEU_TIMEOUT</code>	Tiempo máximo de espera de red (ej. <code>90</code>).
<code>INVESTEU_MAX_RETRIES</code>	Número de reintentos si la web falla (ej. <code>3</code>).

Aquí tienes la **guía técnica detallada** para el script `InvestEU_extract.py`.

Este script es especial porque funciona como un **Scraper Híbrido**. No ataca una sola API, sino que realiza dos tareas muy distintas: "navegar" por la web para sacar la lista de proyectos (HTML) y descargar/leer documentos oficiales (PDF) para sacar los beneficiarios finales.

Manual de Atributos: **InvestEU_extract.py**

1. **--what** (El Modo de Operación)

Define qué parte del portal de InvestEU quieres atacar.

Opción	Descripción	¿Cuándo usarlo?
all	(Por defecto) Ejecuta ambas tareas: descarga la lista web Y procesa los PDFs.	Para la ejecución normal del ETL.
list	Solo hace Web Scraping del listado de operaciones ("Operations List"). Genera operations_list.csv .	Si solo te interesa saber qué proyectos existen, pero no quién recibió el dinero final.
recipients	Solo hace PDF Scraping de los documentos de beneficiarios. Genera final_recipients.csv .	Si la web falla pero quieres extraer datos de los PDFs.

2. **--out-dir** (La Salida)

Define dónde se guardarán los CSV resultantes.

- **Por defecto:** **data/raw/investeu**
- **Archivos generados:**
 - **operations_list.csv** (Datos de la web)
 - **final_recipients_202X.csv** (Datos de las tablas del PDF)

3. **--years** (Etiqueta Informativa)

- **Uso:** **--years 2024**
- **Función:** Es un argumento opcional que ayuda a nombrar el archivo de salida si estás forzando la descarga de un PDF específico manualmente. En la ejecución automática (**all**), el script intenta adivinar el año por sí mismo.



Variables de Entorno (**.env**) - ¡CRÍTICAS!

A diferencia de los otros scripts, este **depende totalmente** de tu archivo **.env** para configuraciones avanzadas que no se pasan por terminal.

Variable	Descripción
INVESTEU_RECIPIENT_PDFS	(Opcional) Lista de URLs de PDFs separadas por comas. Si no la pones, el script usa una URL interna por defecto (la lista oficial del EIB). Úsalo si el EIB publica un PDF nuevo y quieres forzar su descarga.
INVESTEU_BASE_SLEEP	Segundos de espera entre páginas web o descargas de PDF. Recomendado: 300 (5 min) para evitar bloqueos.
INVESTEU_TIMEOUT	Tiempo máximo de espera de red (ej. 90).
INVESTEU_MAX_RETRIES	Número de reintentos si la web falla (ej. 3).



Recetario de Comandos

A. El Comando Estándar (Todo)

Descarga tanto la web como el PDF oficial.

```
python ETL/script/InvestEU_extract.py --what all
```

B. Solo Web Scraping (Rápido)

Si solo quieres actualizar la lista de proyectos aprobados.

```
python ETL/script/InvestEU_extract.py --what list
```

C. Forzar un PDF Nuevo (Avanzado)

Imagina que el EIB saca un nuevo PDF hoy y quieres procesarlo sin esperar a actualizar el código.

1. En tu terminal (o `.env`), defines la URL:

- *Linux/Mac:* `export`
`INVESTEU_RECIPIENT_PDFS="https://www.eib.org/nuevo_reporte_2025.pdf"`
- *Windows Powershell:*
`$env:INVESTEU_RECIPIENT_PDFS="https://www.eib.org/nuevo_reporte_2025.pdf"`

2. Ejecutas el script:

```
python ETL/script/InvestEU_extract.py --what recipients --years 2025
```

4. OECD

Manual de Atributos: `OECD_extract.py`

1. `--only` (El Menú a la Carta)

Este es el atributo más importante. Define qué indicadores específicos quieres descargar del catálogo interno del script.

- **Opciones:**
 - `all`: **(Por defecto)** Intenta descargar TODOS los datasets definidos en el script.
 - `lista, separada, por, comas`: Descarga solo los que pidas.

Claves disponibles (Keys) para tu TFM:

- **Ambientales (Eje Y):** `air_ghg` (Emisiones), `env_tax` (Impuestos verdes), `env_expenditure` (Gasto ambiental), `material_resources`.
- **Económicos (Eje X):** `gdp` (PIB), `productivity`, `labour_force`.
- **Sociales:** `bli_indicators` (Bienestar - Better Life Index), `regional_wellbeing`, `health_expenditure`.
- **Innovación:** `rd_expenditure` (I+D), `patents_ipc`, `vc_investment`.

2. `--start` y `--end` (La Ventana Temporal)

Define el rango de años que se pedirá a la API.

- **Formato:** Año en 4 dígitos (YYYY).
- **Por defecto:** Inicio `2010`, Fin `2023`.

- **Ejemplo:** `--start 2000 --end 2024`

3. Control de Bloqueos (Rate Limiting) - ¡VITAL!

La OCDE bloquea IPs agresivas. Estos atributos controlan la "cortesía" del script.

- **--pause:** Segundos de espera *entre* cada dataset.
 - *Por defecto:* `300` (5 minutos).
 - *Recomendación:* No lo bajes de 60 segundos o te bloquearán.
- **--penalty-429:** Lista de tiempos de castigo si la API devuelve error 429 (Too Many Requests).
 - *Formato:* "seg1,seg2,seg3".
 - *Por defecto:* "300,600,1200" (Espera 5 min, luego 10 min, luego 20 min).

4. --overwrite (El Borrador)

- **Uso:** Flag (sin valor).
 - **Función:** Por defecto, si el archivo `gdp.csv` ya existe, el script se lo salta para ahorrar tiempo. Si pones `--overwrite`, lo borra y lo vuelve a descargar. Úsalo si crees que la descarga anterior quedó corrupta.
-

Recetario de Comandos

A. El Pack "Curva de Kuznets" (Lo esencial)

Descarga solo PIB, Emisiones y Gasto Ambiental para no saturar.

```
python ETL/script/OECD_extract.py \  
--only gdp,air_ghg,env_expenditure \  
--start 1995 --end 2024 \  
--pause 120
```

B. Datos de Bienestar y Sociedad

Para analizar si la percepción de salud mejora con el PIB.

```
python ETL/script/OECD_extract.py \  
--only bli_indicators,health_expenditure,regional_wellbeing \  
--start 2010 --end 2024
```

C. Modo "Reparación" (Forzar descarga)

Si descargaste el PIB pero te diste cuenta de que estaba vacío o mal.

python ETL/script/OECD_extract.py --only gdp --overwrite


6. SENTINEL-2

Manual de Atributos: Sentinel-2_extract.py

1. Argumentos Geográficos (El "Dónde")

Define qué zona del planeta quieres observar.

Atributo	Ejemplo	¿Para qué sirve?
--aoi	--aoi madrid	Área de Interés. Usa preajustes definidos en el código (madrid, tiny) o custom.
--wkt	--wkt "POLYGON((...))"	Geometría Exacta. Obligatorio si usas --aoi custom. Es un string de texto que define el polígono de coordenadas.



| | `--tile` | `--tile 30TVK` | **Cuadrícula MGRS**. Filtra por el identificador único de la "baldosa" (Tile) de Sentinel. Es más preciso que las coordenadas si conoces el código. |

2. Argumentos Temporales (El "Cuándo")

Atributo	Ejemplo	¿Para qué sirve?
<code>--days-back</code>	<code>--days-back 365</code>	Define la ventana de búsqueda: desde HOY hacia atrás X días.
<code>--orderby</code>	<code>--orderby "ContentDate/Start asc"</code>	Define el orden de descarga. • <code>desc</code> (defecto): Los más nuevos primero. • <code>asc</code>: Los más antiguos primero.

3. Argumentos de Datos (El "Qué")

Aquí decides si quieres una foto bonita, un mapa de nubes o datos científicos puros.

Atributo	Ejemplo	¿Para qué sirve?
<code>--asset</code>	<code>--asset tci</code>	Productos Procesados. • <code>tci</code>: <i>True Color Image</i>. Imagen visual (RGB). Se guarda como .png. • <code>scl</code>: <i>Scene Classification Layer</i>. Mapa de nubes y terreno. Se guarda como .jp2.

<code>--bands</code>	<code>--bands B04,B08</code>	Datos Científicos. Descarga las bandas espectrales crudas (Rojo, Infrarrojo, etc.).  Si usas esto, el script ignora <code>--asset</code> .
<code>--only-l2a</code>	(Sin valor)	Nivel de Procesado. Por defecto (<code>True</code>) solo descarga nivel 2A (corregido atmosféricamente, listo para análisis).
<code>--no-only-l2a</code>	(Sin valor)	Permite descargar nivel 1C (sin corrección atmosférica). No recomendado para comparar fechas distintas.

4. Control Técnico (La Ejecución)

Atributo	Ejemplo	¿Para qué sirve?
<code>--download</code>	(Flag)	Interruptor Maestro. Si NO lo pones, el script solo busca ("dry run") y te dice cuántos archivos hay, pero no baja nada . Ponlo siempre en producción.
<code>--max-downloads</code>	<code>--max-downloads 50</code>	Seguridad. Detiene el script tras bajar X archivos. Vital para no llenar el disco duro.
<code>--out-dir</code>	<code>--out-dir data/s2</code>	Carpeta base. El script creará automáticamente subcarpetas organizadas (<code>zips</code> , <code>TCI_Visual</code> , etc.) dentro de esta ruta.
<code>--csv</code>	<code>--csv reporte.csv</code>	Nombre del archivo CSV donde se guarda el listado de metadatos encontrados.



Recetario de Comandos (Para tu TFM)

Estos son los 3 comandos esenciales que cubren todas las necesidades de tu proyecto de la Curva de Kuznets.

A. El Dato Científico (Cálculo NDVI)

Descarga las bandas Roja (B04) e Infrarroja (B08) para calcular la vegetación.

```
python ETL/script/Sentinel-2_extract.py \  
--aoi madrid \  
--bands B04,B08 \  
--days-back 365 \  
--max-downloads 50 \  
--download
```

- **Salida:** `data/s2/NDVI_Bandas/YYYY-MM-DD/`

B. La Máscara de Limpieza (Quitar Nubes)

Descarga el mapa de clasificación para saber qué píxeles ignorar.

```
python ETL/script/Sentinel-2_extract.py \  
--aoi madrid \  
--asset scl \  
--days-back 365 \  
--max-downloads 50 \  
--download
```

- **Salida:** `data/s2/SCL_Nubes/YYYY-MM-DD/`

C. La Evidencia Visual (Informe)

Descarga fotos reales a color para mostrar en el documento.

```
python ETL/script/Sentinel-2_extract.py \  
--aoi madrid \  
--asset tci \  
--days-back 30 \  
--max-downloads 5 \  
--download
```

- **Salida:** `data/s2/TCI_Visual/YYYY-MM-DD/`