



Universidad Europea

Proyecto Big Data

**Informe Final:
Green Turning Point (GTP)**

11/01/2026

Juan Manuel Palencia Osorio

Pablo Mata Rius

Pablo Sánchez Ruiz

María Paula Aguirre

1. Resumen Ejecutivo: La Propuesta de Valor

Green Turning Point (GTP) no es solo un estudio académico, es una plataforma de inteligencia financiera basada en Big Data. En un contexto donde la inversión ESG (Environmental, Social, and Governance) domina los flujos de capital, GTP ofrece una ventaja competitiva única: **la detección temprana**.

Utilizamos datos satelitales masivos y econometría avanzada para identificar el momento exacto "Turning Point" en que una ciudad europea desacopla su crecimiento económico de la degradación ambiental. Esta señal, invisible para el análisis financiero tradicional, nos permite anticipar revalorizaciones en el sector energético y diseñar **Carteras de Inversión Verdes** con un ratio riesgo-beneficio optimizado.

2. Arquitectura Tecnológica y Metodología de Desarrollo

El desarrollo de GTP ha seguido un enfoque de **Ingeniería de Datos Robusta**, garantizando la reproducibilidad, escalabilidad y eficiencia en el manejo de grandes volúmenes de información geoespacial y financiera.

2.1 Entorno de Desarrollo y Colaboración

- **Desarrollo Ágil:** Todo el código ha sido desarrollado en local utilizando **Visual Studio Code**, manteniendo un control de versiones estricto mediante **GitHub**. Hemos trabajado con ramas de desarrollo paralelas que convergen en la rama principal (main) tras la validación de cada sprint, asegurando la integridad del código en producción.
- **Contenerización:** Se ha implementado **Docker** para encapsular nuestras dependencias (librerías geoespaciales como rasterio, gdal, pyspark), eliminando el problema de "funciona en mi máquina" y facilitando el despliegue en cualquier servidor.

2.2 Procesamiento en LORCA

Dada la magnitud de los datos satelitales (miles de imágenes TIFF de alta resolución), el procesamiento local era inviable. Migramos la carga de trabajo al **Clúster LORCA** de la universidad.

- **Paralelización:** Ejecutamos scripts de Python optimizados para procesar múltiples ciudades simultáneamente, aprovechando los núcleos del clúster.
- **Persistencia y Automatización:**
 - **GNU Screen:** Utilizamos sesiones de screen para mantener los procesos de extracción y transformación (ETL) activos en segundo plano durante días, asegurando que la desconexión SSH no interrumpiera el flujo.
 - **Cronjobs:** Implementamos tareas programadas (cron) para automatizar la verificación de descargas y la ejecución periódica de scripts de limpieza, garantizando que el pipeline de datos funcionara 24/7 sin supervisión humana constante.

3. Ingeniería de Datos: El Pipeline ETL

Hemos construido un data lake que fusiona tres dimensiones críticas: **Observación de la Tierra, Economía Oficial y Mercados Financieros.**

3.1 Extracción y Fuentes (Raw Data)

- **Datos Satelitales (Copernicus):**
 - **Sentinel-2 y HRL:** Extrajimos series temporales de índices de vegetación (NDVI) y capas de alta resolución (**High Resolution Layers**) como Tree Cover Density e Imperviousness (impermeabilización del suelo).
 - **Sentinel-5P:** Procesamiento de archivos NetCDF para medir la concentración de NO2 (calidad del aire).
 - **Periodicidad:** Mensual para satélites, permitiendo una granularidad que las estadísticas anuales no ofrecen.
- **Datos Económicos (Eurostat/INE):** PIB per cápita, densidad poblacional y empleo sectorial a nivel de FUA (Functional Urban Area) con periodicidad anual.
- **Datos Financieros (Yahoo Finance):** Cotizaciones de empresas energéticas europeas para el modelado de carteras.

3.2 Transformación y Limpieza (Processed Data)

La fase de transformación fue crítica. Utilizamos **Apache Spark** y scripts de Python (Pandas/Numpy) en el clúster para:

1. **Limpieza Geoespacial:** Filtrado de nubes, corrección de valores "No Data" (255) en imágenes satelitales y recorte de imágenes mediante máscaras de coordenadas exactas de las ciudades.
2. **Normalización:** Estandarización de unidades monetarias y temporales para alinear los datos satelitales (mensuales) con los económicos (anuales).
3. **Generación del Dataset Maestro:** El resultado final es un **CSV consolidado y limpio**, listo para alimentar modelos de Machine Learning. Este dataset contiene una fila por ciudad con todas sus métricas ambientales, económicas y sociales perfectamente alineadas (cross-sectional data 2018 para máxima precisión ya que incluye los datos de HRL).

3.3 Cobertura y Alcance Geoespacial

Para garantizar la validez econométrica del modelo y la escalabilidad comercial de la plataforma, no nos hemos limitado a las capitales nacionales. Hemos desplegado una arquitectura capaz de monitorizar **300 Áreas Urbanas Funcionales (FUAs)** distribuidas en **20 países**, seleccionadas estratégicamente para estudiar la diversidad climática, económica y regulatoria del continente.

Métricas del Alcance:

- **Volumen:** 300 ciudades monitorizadas simultáneamente.

- **Diversidad Geográfica:** Desde el ártico noruego (Tromsø) hasta el mediterráneo griego (Heraklion), pasando por los centros financieros (Zúrich, Frankfurt, Londres) y los motores industriales de Europa del Este (Katowice, Ostrava).
- **Cobertura Nacional:**
 - **Sur de Europa:** España (26), Italia (24), Portugal (10), Grecia (10).
 - **Centro/Norte:** Alemania (38), Francia (26), Países Bajos (12), Bélgica (10).
 - **Este de Europa:** Polonia (18), Rumanía (10), Rep. Checa (10), Hungría (10).
 - **Nórdicos/Otros:** Suecia, Dinamarca, Finlandia, Noruega, Suiza, Austria, Irlanda (10 cada uno).

Valor para el Inversor: Esta dispersión en los datos nos permite entrenar el algoritmo de Machine Learning con una variedad de escenarios fortaleciendo la robustez de los resultados. No solo analizamos economías ricas, analizamos **economías en transición** siendo este mismo el área de estudio en cuestión. Esto es vital para detectar el "Turning Point" de Kuznets, ya que necesitamos comparar ciudades que aún contaminan para crecer (fase pre-turning point) con ciudades que ya se han desacoplado (fase post-turning point).

Hemos georreferenciado las coordenadas exactas de los centroides de estas 300 áreas para automatizar la extracción de imágenes satelitales, creando una red de datos que cubre a más de **250 millones de habitantes**.

3.4 Estructura del Dataset Maestro

El resultado de nuestro procesamiento masivo es un dataset analítico de alta dimensionalidad (1182 filas x 32 columnas). Lejos de ser un simple volcado de datos, cada variable ha sido seleccionada para alimentar una parte específica de nuestro modelo híbrido de Kuznets (Econometría + Finanzas).

A continuación, justificamos la arquitectura de este CSV final, dividiendo las variables por su función estratégica:

A. Dimensión Geo-Temporal (La Base del Panel)

City, Country_Name, Country_Code: Identificadores únicos normalizados (ISO 3166-1) que permiten cruzar nuestros datos con cualquier base de datos mundial (FMI, Banco Mundial). Year, Month: Claves temporales que habilitan el análisis de estacionalidad (ej. ¿Sube el NO2 en invierno por calefacciones?) y la detección de tendencias a largo plazo.

B. Dimensión Ambiental: La Salud Real de la Ciudad (Variables E)

Estas columnas son el **input objetivo** que sustituye a las estadísticas gubernamentales, a menudo sesgadas o desactualizadas.

- **Indicadores de Vegetación (Sentinel-2):**
 - NDVI_Mean y NDVI_Median: Son el "pulso" verde de la ciudad que miden la fotosíntesis activa.
 - NDVI_Gini: Adaptamos el Coeficiente de Gini (usado para medir desigualdad de riqueza) para medir la Desigualdad Verde. ¿Tiene la ciudad parques para todos (Gini - 0) o solo un gran bosque en un barrio rico (Gini - 1)?

- Pct_Grey_Area vs Pct_Green_Area: Métricas binarias críticas para urbanismo. Miden qué porcentaje del suelo es biológicamente muerto (cemento) frente a vivo.
- **Indicadores Estructurales (HRL - Copernicus):**
 - Imperviousness_Mean y Pct_Dense: Miden el sellado del suelo. Un valor alto aquí correlaciona directamente con el riesgo de inundaciones y el efecto "Isla de Calor Urbana".
 - TreeCover_Pct_Cover: Diferencia entre tener "césped" (NDVI alto) y tener "árboles maduros" (Tree Cover alto), vital para la absorción de CO2 real.
- **Calidad del Aire (Sentinel-5P):**
 - NO2_Mean, Max, Min: Huella directa de la actividad industrial y tráfico de combustión. Al tener el Max y Min, podemos detectar picos de contaminación aguda (alertas sanitarias) frente a la contaminación crónica.

C. Dimensión Económica: El Motor del Modelo (Variables Y)

- GDP_Per_Capita: La variable independiente clave para la Curva de Kuznets. Al estar ajustada a paridad de poder adquisitivo (PPP) cuando es posible, permite comparar justamente la riqueza real de un ciudadano de Sofía con uno de Zúrich.

D. Dimensión Financiera: La Señal de Inversión (El α)

Aquí integramos métricas bursátiles agregadas por país para correlacionar la sostenibilidad con la rentabilidad.

- Fin1_Tickers y Fin1_Companies: Trazabilidad total. Sabemos exactamente qué empresas componen la "Cartera Energía" de cada país.
- Fin1_Sector_Avg_Price y Avg_Volatility:
 - Precio: Nos dice la valoración de mercado actual.
 - Volatilidad: Mide el Riesgo. Un país en transición desordenada tendrá empresas con alta volatilidad (incertidumbre regulatoria).
- Fin2_Sector_Avg_Beta: Mide el riesgo sistémico. ¿Cómo de sensible es el sector energético de ese país a los choques globales? Una Beta baja indica un sector defensivo y estable.
- Fin2_Sector_Avg_PE (Price/Earnings): Ratio fundamental. Si un país cruza el "Turning Point" verde y sus empresas tienen un P/E bajo (están baratas), el algoritmo lanza una señal de **COMPRA FUERTE**.

4. Analítica Avanzada: El Motor de Decisión

Con los datos procesados, desplegamos nuestra estrategia analítica basada en dos pilares:

4.1 La Ecuación de Kuznets (EKC): Especificación Logarítmica

Para validar empíricamente la hipótesis, utilizamos una especificación econométrica no lineal en forma **logarítmica**:

$$\ln(E_{it}) = \alpha + \beta_1 \ln(Y_{it}) + \beta_2 (\ln(Y_{it}))^2 + \gamma \ln(Z_{it}) + \mu_i + \varepsilon_{it}$$

Donde:

– $\ln(E_{it})$: Logaritmo natural de la Degradación Ambiental (NO_2 / Impermeabilización / Tree Cover Density inverso) en la ciudad i en el año t .

– $\ln(Y_{it})$: Logaritmo del PIB per cápita.

– $(\ln(Y_{it}))^2$: Término cuadrático clave para capturar la forma de "U invertida".

– $\ln(Z_{it})$: Logaritmo del vector de Variables de Control (Densidad poblacional, % Empleo Industrial, etc.).

– μ_i : Efectos fijos por ciudad (captura geografía invariable).

– α : Representa el **Nivel Base de Degradación Ambiental** común a todas las ciudades cuando las variables explicativas son cero (en términos logarítmicos). Econométricamente, recoge el estado "por defecto" de la tecnología disponible en el periodo base.

– β (Elasticidades de la Renta):

- β_1 (Efecto Escala): Se espera que sea **positivo** (>0). Indica cuánto aumenta la contaminación por cada 1% que crece el PIB debido a la mayor actividad industrial y consumo.
- β_2 (Efecto Técnica): Se espera que sea **negativo** (<0). Es el término cuadrático de la curva. Representa la fuerza correctora: adopción de tecnologías limpias y eficiencia energética.

– γ (Gamma - Elasticidad de Control): Mide el impacto porcentual de las variables estructurales Z (como la densidad de población o el % de empleo industrial) sobre el medio ambiente, manteniendo constante la riqueza. Nos permite limpiar el modelo del ruido demográfico.

– μ_i (Efectos Fijos por Ciudad): Captura la **heterogeneidad no observada** de cada ciudad que es constante en el tiempo, aislando el efecto puramente económico del geográfico.

– ε_{it} (Término de Error Estocástico): Representa los choques aleatorios que el modelo no puede predecir (ej. un incendio forestal puntual o la pandemia de COVID-19). Un ε bajo y sin patrones indica que nuestro modelo es robusto y ha capturado bien la realidad.

Justificación de la Transformación Logarítmica (ln):

Hemos optado por transformar las variables a logaritmos por tres razones estadísticas y económicas:

1. **Interpretación como Elasticidades:** A diferencia del modelo lineal, los coeficientes β nos indican cambios porcentuales. Nos permite decir: "Un aumento del 1% en el PIB reduce la contaminación en un X%", lo cual es mucho más relevante para el análisis de carteras de inversión que los cambios en unidades absolutas.
2. **Normalización de Datos (Skewness):** Las variables económicas (Renta) y ambientales (Emisiones) no siguen una distribución normal, suelen tener "colas largas" (asimetría positiva). Aplicar ln comprime la escala, acercando los datos a una distribución normal (Gaussiana), cumpliendo así los supuestos teóricos de los modelos de regresión.
3. **Heterocedasticidad:** Reduce la varianza del error en valores altos (ciudades muy ricas o muy contaminadas), evitando que los datos extremos distorsionen la fiabilidad del modelo.

4.2 Sistema de Trading Híbrido (GARCH + ML + Black-Litterman)

Para los inversores, no basta con saber "dónde" invertir, sino "cómo". A futuro queremos integrar un sistema de trading con los siguientes modelos para apoyar los resultados obtenidos con Kuznets:

- **Riesgo:** Modelos **GARCH** para estimar la volatilidad condicional del mercado.
- **Señal:** Modelos de **Machine Learning (XGBoost)** entrenados con el dataset maestro para predecir tendencias.
- **Asignación:** Modelo **Black-Litterman** para optimizar los pesos de la cartera, suavizando las predicciones del ML con el equilibrio de mercado.

5. Implementación Técnica: Arquitectura Big Data y Procesamiento Distribuido

La viabilidad del proyecto GTP dependía de la capacidad para procesar terabytes de información no estructurada (imágenes satelitales) y fusionarla con datos estructurados (finanzas y economía). Para ello, hemos diseñado un pipeline ETL (Extract, Transform, Load) de alto rendimiento desplegado en el **Clúster LORCA** de la universidad.

5.1 Infraestructura y Persistencia

El procesamiento local era inviable dada la magnitud del dataset (series temporales de imágenes mensuales para 302 ciudades). La solución se diseñó en torno al procesamiento distribuido:

- **Entorno HPC (High Performance Computing):** Despliegue en el clúster LORCA, permitiendo la paralelización masiva de tareas de lectura y cálculo matricial.

- **Persistencia de Procesos:** Implementación de sesiones persistentes mediante **GNU Screen**, lo que garantizó la continuidad del procesamiento (que excede las 24 horas en fases de carga completa) frente a desconexiones de red o cierres de sesión SSH.
- **Automatización (Cronjobs):** Programación de tareas cron para la vigilancia de descargas y la ejecución secuencial de scripts, eliminando la necesidad de intervención humana durante las fases críticas de ingestión de datos.

5.2 Optimización del Pipeline con Apache Spark

El procesamiento se ha desarrollado en **PySpark**, aplicando técnicas avanzadas de optimización para reducir la latencia y el consumo de memoria RAM:

1. **Alimentación Inteligente (pathGlobFilter):** Implementamos filtros nativos a nivel de sistema de archivos para discriminar tipos de archivo (.zip, .tif) antes de la lectura, optimizando el I/O (Input/Output) del disco.
2. **Transformación de Imágenes a Tensores:**
 - Desarrollamos **UDFs (User Defined Functions)** personalizadas para descomprimir al vuelo archivos ZIP de Sentinel-2 y Sentinel-5P, extrayendo únicamente las bandas espectrales necesarias.
 - Las imágenes se convierten a tensores normalizados (128 x128x1), quedando listas para alimentar futuras redes neuronales convolucionales (CNN) sin pre-procesamiento adicional.
3. **Optimización de Cruces Espaciales (Broadcast Joins):**
 - Para asignar cada imagen satelital a su ciudad (FUA) correspondiente, evitamos el Shuffle Join tradicional.
 - Utilizamos la estrategia de **Broadcast Join**, replicando la tabla de coordenadas geoespaciales (pequeña) en todos los nodos del clúster. Esto redujo drásticamente el tráfico de red y aceleró el cruce de datos geoespaciales.
4. **Gestión de Particiones (repartition):**
 - Para evitar el problema de "small files" (miles de archivos pequeños que ralentizan la lectura), re-particionamos los datos de salida basándonos en el fua_id. Esto garantiza que la información de cada ciudad se almacene de forma contigua, acelerando las consultas posteriores del modelo.

5.3 Integración y Limpieza del Dataset Maestro

El script final (merge.py) actúa como el orquestador que unifica las tres dimensiones del estudio:

- **Normalización Financiera:** Procesamiento de datos de Yahoo Finance para generar métricas de volatilidad y retorno anual (log_close_price, volatility), alineadas temporalmente con los datos macroeconómicos.
- **Saneamiento de Datos (Data Quality):**
 - Detección y filtrado de outliers en series temporales (PIB Trimestral INE).
 - Corrección de anomalías en datos satelitales (eliminación de píxeles nulos o >100 en capas HRL).
 - Tipado estricto de datos (Casting) para asegurar la integridad numérica en los modelos de regresión.

5.4 Resultado: Activos Listos para Producción (Model Ready)

El pipeline no solo genera un CSV, sino una estructura de datos escalable almacenada en formato **Parquet** (columnar y comprimido), que incluye:

1. **finance_panel**: Histórico bursátil depurado.
2. **eurostat_panel**: Panel macroeconómico armonizado.
3. **images_tensors**: Base de datos de tensores de imágenes lista para Deep Learning.
4. **master_dataset**: La tabla final analítica para la ecuación de Kuznets

6. Conclusión y Estado Actual

A fecha de hoy, disponemos de:

1. **Infraestructura Validada**: Un pipeline ETL probado en entorno el entorno LORCA capaz de procesar los datos mensualmente con cronjob para actualizar el csv maestro.
2. **Datos de Alta Calidad**: Un **Dataset Final depurado**, libre de ruido y errores de medición, que fusiona la realidad física (satélite) con la realidad económica.
3. **Modelo de Negocio Claro**: Una herramienta con el objetivo de ofrecer un retorno por encima del mercado a gestores de activos mediante señales ecológicas anticipadas.